

# Topic Modelling sobre sesiones de la Cámara de Diputados de la Nación Argentina

## Resumen

El objetivo de este trabajo es aplicar técnicas de Topic Modelling sobre las versiones taquigráficas de las sesiones de la Cámara de Diputados de la Nación Argentina, disponibles públicamente en el sitio oficial (<https://www.diputados.gob.ar/sesiones/>). El dataset abarca sesiones desde 1984 hasta el período actual (2026). Sin tener la data desde el 1991 a 2000 debido a que la Cámara de Diputados aún se encuentra en proceso de digitalización de esos registros, según indica el propio sitio. Se busca identificar los temas predominantes en el discurso parlamentario y analizar cómo evolucionan a lo largo del tiempo, correlacionándolos con el contexto político y social de cada período.

## Datos

La fuente de datos es el Diario de Sesiones publicado por la Dirección de Taquígrafos de la Honorable Cámara de Diputados de la Nación Argentina. Estos documentos contienen la transcripción completa de los debates parlamentarios, actas de votación e inserciones solicitadas por los legisladores. Los datos son de dominio público según lo indica el propio sitio.

El dataset fue construido mediante un scraper desarrollado en Python que realiza el siguiente proceso: primero se extrae la lista de sesiones y su metadata (período, reunión, fecha, tipo de sesión) desde la página principal del sitio; luego, para cada sesión, se construye la URL del PDF correspondiente al Diario de Sesiones y se descarga en memoria; finalmente, se extrae el texto completo del PDF utilizando la librería pypdf y se almacena en archivos Parquet, uno por período parlamentario.

Cada registro del dataset contiene: identificador de período, número de reunión, fecha de la sesión, descripción (tipo de sesión), URL de la sesión y el texto completo extraído del PDF. En total el dataset cuenta con 33 períodos parlamentarios, 1125 sesiones, de las cuales 1018 contienen texto extraído exitosamente. Las sesiones sin texto corresponden principalmente a actos formales sin debate (asambleas legislativas de proclamación, sesiones no efectuadas, videos etc.). El peso total del dataset en formato Parquet es de aproximadamente 428 MB.

El código del scraper y los datos se encuentran disponibles en el repositorio:  
<https://github.com/fedesaroka/nlp-sesiones-diputados>

## Analisis Exploratorio

A continuación se presentan estadísticas descriptivas del corpus y visualizaciones que caracterizan el dataset antes de la etapa de modelado.


### Estadísticas generales del corpus

| Métrica                         | Valor       |
|---------------------------------|-------------|
| Períodos parlamentarios         | 33          |
| Sesiones totales                | 1.125       |
| Sesiones con texto extraído     | 1.018       |
| Sesiones sin texto              | 107         |
| Total de palabras en el corpus  | 139,124,685 |
| Promedio de palabras por sesión | 136,665     |
| Mediana de palabras por sesión  | 70,787      |
| Mínimo de palabras              | 240         |
| Máximo de palabras              | 1,373,875   |

|                |                           |
|----------------|---------------------------|
| Rango temporal | 1983 - 1990 & 2001 - 2026 |
|----------------|---------------------------|


### Distribución de palabras por sesión

La distribución de la cantidad de palabras por sesión está muy sesgada a la derecha, con la gran mayoría de las sesiones concentradas por debajo de las 100.000 palabras (la mediana es ~70.787). Sin embargo, hay outliers importantes que llegan hasta 1.4 millones de palabras — probablemente sesiones maratónicas como el debate de la Ley Ómnibus o presupuestos. Esto sugiere que para el topic modelling va a convenir segmentar las sesiones más largas o trabajar con chunks.



### Evolución temporal de las sesiones

La cantidad de sesiones por año muestra una tendencia decreciente clara. En los '80 se registraban 50-70 sesiones por año, y desde 2010 en adelante ronda las 15-25. El hueco entre ~1990 y ~2000 corresponde a los períodos que no se pudieron descargar (el bache 108-118 que faltaba en el sitio). Los picos en 1986 y 1988 coinciden con períodos de alta actividad legislativa durante el gobierno de Alfonsín.




### Evolución del largo promedio de las sesiones

El promedio de palabras por sesión a lo largo de los años muestra una tendencia creciente notable. Las sesiones de los '80 promediaban ~100.000 palabras, pero desde 2010 el promedio sube a 150.000-250.000, con un pico enorme en 2015 (~385.000 palabras promedio). Esto sugiere que aunque se hacen menos sesiones por año, cada sesión es mucho más larga — probablemente porque se acumulan más temas en cada una.



### Tipos de sesión


Se clasificaron las sesiones según su tipo a partir de la descripción. La distribución resultante es:



Las sesiones ordinarias y especiales son las más frecuentes (~340 y ~310 respectivamente), seguidas por expresiones en minoría (~200). Las sesiones extraordinarias, informativas y preparatorias son mucho menos comunes. Las asambleas legislativas son muy pocas porque son eventos puntuales (aperturas, juramentos presidenciales).

### Palabras más frecuentes

Se realizó un conteo de frecuencia de palabras sobre todo el corpus, removiendo stopwords del español y términos propios del formato parlamentario ("señor presidente", "diputado", "artículo", etc.). Las 30 palabras más frecuentes son:



Aparecen "diputados", "nacional", "poder" y "ejecutivo" como las más frecuentes — son palabras del vocabulario institucional que probablemente haya que agregar a las stopwords para el topic modelling. Lo más interesante son las palabras temáticas que asoman: "gobierno", "presupuesto", "social", "trabajo", "provincia". También aparecen nombres propios como "juan", "carlos" y "maría", lo cual indica que el preprocesamiento va a necesitar un paso de remoción de nombres. La palabra "ción" aparece porque el extractor de PDF corta palabras como "educa-ción" o "resolu-ción" entre líneas — otro tema a resolver en el preprocesamiento.

## Propuesta de análisis

Se propone aplicar Topic Modelling para descubrir los temas latentes en el discurso parlamentario argentino y analizar su evolución temporal. Las preguntas de investigación que guían el trabajo son:

1. ¿Cuáles son los temas predominantes en las sesiones de la Cámara de Diputados a lo largo de las últimas décadas?

2. ¿Cómo varía la distribución de tópicos entre distintos períodos parlamentarios? ¿Es posible identificar la aparición, crecimiento y desaparición de ciertos temas en función del contexto político y social?
3. ¿Existen diferencias temáticas entre los distintos tipos de sesión (ordinarias, especiales, extraordinarias)?
4. ¿Se pueden identificar diferencias temáticas entre bloques o partidos políticos? ¿Hay tópicos que son "propiedad" de ciertos sectores del arco político?

El trabajo se desarrollará en dos etapas. En la primera, se trabajará con el texto completo de cada sesión como unidad de análisis, aplicando Topic Modelling a nivel de sesión para obtener una visión general de los temas tratados y su evolución temporal. En la segunda etapa, se realizará un procesamiento más fino del texto para segmentar cada sesión en intervenciones individuales, identificando qué legislador habla en cada momento a partir de los patrones del formato taquigráfico (por ejemplo, "Sr. Pérez.—"). Esto permitirá vincular cada intervención con el legislador correspondiente y, a través de fuentes complementarias, con su bloque político. Con esta granularidad será posible analizar los tópicos no solo por año o tipo de sesión, sino también por partido político y por legislador.

Para el modelado se planea utilizar BERTopic como enfoque principal, dado que permite trabajar con embeddings contextuales y ofrece herramientas de visualización como Topics over Time. Se evaluarán distintos modelos de embeddings para la representación vectorial de los textos, incluyendo modelos multilingües como paraphrase-multilingual-MiniLM-L12-v2 y modelos específicos en español, comparando la calidad de los tópicos resultantes. Como baselines se utilizarán también LDA (Latent Dirichlet Allocation) y NMF (Non-negative Matrix Factorization), lo que permitirá comparar el rendimiento de enfoques clásicos basados en frecuencia de términos frente al enfoque basado en embeddings de BERTopic. La evaluación de los modelos se realizará tanto cuantitativamente (coherencia de tópicos, diversidad) como cualitativamente (interpretabilidad de los tópicos descubiertos). El preprocesamiento incluirá tokenización, remoción de stopwords en español, limpieza del formato propio de las versiones taquigráficas (encabezados, paginación, numeración de artículos) y tratamiento de palabras cortadas entre líneas (por ejemplo, "resolu-ción").

La hipótesis principal es que los tópicos descubiertos reflejarán la agenda política de cada período, y qué eventos significativos (crisis económicas, cambios de gobierno, debates de leyes emblemáticas) se manifestarán como cambios en la distribución de tópicos. A nivel partidario, se espera encontrar diferencias temáticas que reflejen las prioridades discursivas de cada bloque.

## Experimentos

A continuación se detalla el plan experimental organizado por pregunta de investigación. Cada experimento especifica qué se va a hacer, cómo y por qué.

### Preprocesamiento común a todos los experimentos

Antes de correr cualquier modelo, se aplicará el siguiente pipeline de limpieza sobre el texto crudo extraído de los PDFs:

1. **Reunión de palabras cortadas entre líneas:** se detectarán patrones del tipo "resolución" y se reunirán en una sola palabra. Esto es necesario porque el extractor de PDF (pypdf) corta palabras con guión al final de línea, generando tokens espurios como "ción" que aparecen en el top 30 de frecuencias.
2. **Remoción de encabezados y metadatos repetitivos:** se eliminarán los headers de página (nombre del diario de sesiones, numeración de páginas, fechas repetidas en cada página) usando patrones regex específicos del formato taquigráfico.
3. **Remoción de stopwords extendidas:** se partirá de las stopwords de spaCy en español y se agregará una lista custom de términos del vocabulario parlamentario que no aportan información temática: "señor", "presidente", "diputado", "diputados", "cámara", "artículo", "proyecto", "resolución", "comisión", "sesión", "votación", "honorable", "nación", "nacional", entre otros. Esta lista se refinará iterativamente al inspeccionar los primeros resultados de los modelos.
4. **Remoción de nombres propios:** se utilizará NER (Named Entity Recognition) con spaCy (`es_core_news_lg`) para identificar y remover entidades de tipo PER (persona). Esto elimina el ruido generado por nombres como "juan", "carlos", "maría" que aparecen frecuentemente por las menciones a legisladores.
5. **Tokenización y lematización:** se lematizará con spaCy para reducir la dimensionalidad del vocabulario (e.g., "trabajadores" → "trabajador", "presupuestos" → "presupuesto").
6. **Segmentación en chunks:** dado que las sesiones varían entre 240 y 1.4M palabras (mediana ~70K), las sesiones más largas se segmentarán en chunks de ~5.000 palabras con overlap de 500 palabras. Esto es necesario tanto para LDA/NMF (documentos más homogéneos) como para BERTopic (los modelos de embeddings tienen límite de tokens). Cada chunk hereda la metadata de la sesión (fecha, período, tipo).

**Nota sobre la granularidad de los datos:** el dataset ya se encuentra segmentado a nivel de intervención individual de cada legislador (cada registro contiene: período, fecha, tratamiento, apellido, número de intervención y texto). Esta estructura se aprovechará directamente en el Experimento 4. Para los Experimentos 1, 2 y 3, que operan a nivel de sesión, se reconstruirá el texto completo de cada sesión concatenando las intervenciones correspondientes.

**Nota sobre alcance temporal del Experimento 4:** la información de bloques políticos de los diputados está disponible desde el 10 de diciembre de 2007 en adelante (fuente: datos abiertos de la HCDN), por lo que el análisis por bloque político (Experimento 4) se restringirá al período 2007-2026. Los Experimentos 1, 2 y 3 operan sobre el corpus completo (1983-1990 y 2001-2026).



# Experimento 1: Descubrimiento de tópicos predominantes

**Pregunta:** ¿Cuáles son los temas predominantes en las sesiones de la Cámara de Diputados a lo largo de las últimas décadas?

## Qué se va a hacer

Entrenar tres modelos de Topic Modelling sobre el corpus completo y comparar la calidad de los tópicos descubiertos:

- **LDA** (Latent Dirichlet Allocation) — baseline clásico basado en co-ocurrencia de términos
- **NMF** (Non-negative Matrix Factorization) — baseline clásico, suele producir tópicos más específicos que LDA
- **BERTopic** — enfoque basado en embeddings contextuales

## Cómo se va a hacer

### LDA y NMF:

- Representación: TF-IDF sobre el corpus preprocesado (sin lematizar para NMF, lematizado para LDA).
- Parámetros a explorar: número de tópicos  $k \in \{10, 15, 20, 30, 50\}$ . Se elegirá el  $k$  óptimo por coherencia (ver métricas abajo).
- Implementación: `sklearn.decomposition.LatentDirichletAllocation` y `sklearn.decomposition.NMF`.

### BERTopic:

- Embeddings: se evaluarán dos modelos:
  - `paraphrase-multilingual-MiniLM-L12-v2` (multilingual, liviano, 384 dims)
  - `hiiamsid/sentence_similarity_spanish_es` (específico español, si el rendimiento lo justifica)
- Reducción de dimensionalidad: UMAP (`n_neighbors=15`, `n_components=5`, `min_dist=0.0`, `metric='cosine'`)
- Clustering: HDBSCAN (`min_cluster_size=15`, `min_samples=5`, `metric='euclidean'`)
- Representación de tópicos: c-TF-IDF (default de BERTopic) + KeyBERTInspired como representation model para refinar las palabras clave.
- Se evaluará `nr_topics="auto"` vs fijar un rango similar al de LDA/NMF para comparabilidad.

## Métricas de evaluación

| Métrica                | Qué mide                                                                         | Implementación                                                                                              |
|------------------------|----------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------|
| Coherence Score (C_v)  | Coherencia semántica de las palabras de cada tópico                              | <code>gensim.models.CoherenceModel</code> con <code>coherence='c_v'</code>                                  |
| Topic Diversity        | Proporción de palabras únicas en el top-N de todos los tópicos (1 = sin overlap) | Cálculo manual: <code>unique words / total words</code> en top-10 de cada tópico                            |
| Evaluación cualitativa | Interpretabilidad humana de los tópicos                                          | Inspección manual de los top-10 términos de cada tópico; asignación de etiquetas descriptivas por el equipo |

## Por qué?

LDA y NMF sirven como baselines bien establecidos en la literatura de Topic Modelling. BERTopic captura relaciones semánticas que los modelos basados en bag-of-words no pueden (e.g., "inflación" y "precios" aparecerían en el mismo tópico por cercanía en el espacio de embeddings, aunque no co-ocuran en los mismos documentos). La comparación permite evaluar si la complejidad adicional de BERTopic se justifica en este corpus.

## Experimento 2: Evolución temporal de tópicos

**Pregunta:** ¿Cómo varía la distribución de tópicos entre períodos parlamentarios? ¿Se pueden identificar aparición, crecimiento y desaparición de temas en función del contexto político y social?

### Qué se va a hacer

Analizar cómo cambia la prevalencia de cada tópico a lo largo del tiempo, utilizando el mejor modelo del Experimento 1.

### Cómo se va a hacer

- **BERTopic Topics over Time:** se usará la función `.topics_over_time()` de BERTopic, pasando los timestamps (fechas de sesión) como parámetro. Se agrupará por año para suavizar la señal y por período presidencial para el análisis político.
- **Para LDA/NMF:** se calculará la distribución de tópicos promedio por año (promedio de los vectores  $\theta$  de los documentos de cada año) y se graficará la evolución con stacked area charts o heatmaps.
- **Períodos de interés para validación cualitativa:**
  - 1983-1989 (retorno democrático, gobierno de Alfonsín — juicio a las juntas, ley de divorcio, hiperinflación)
  - 2001-2003 (crisis económica, default, emergencia social)

- 2008 (conflicto con el campo, Resolución 125)
  - 2010 (matrimonio igualitario)
  - 2012 (expropiación de YPF)
  - 2017-2018 (debate IVE)
  - 2023-2026 (Ley Bases / Ley Ómnibus, reforma de Ley de Glaciares)
- Se espera que los tópicos descubiertos reflejen estos eventos — si un modelo no los captura, es señal de mala calidad temática.
- **Visualización:** heatmap de tópicos × años (intensidad = prevalencia), complementado con line plots para los tópicos más relevantes. Se usará Plotly para las visualizaciones interactivas.

## Por qué

La dimensión temporal es el eje central del trabajo. No alcanza con saber qué temas existen; lo valioso es ver cómo la agenda parlamentaria responde a la coyuntura. Topics over Time de BERTopic está diseñado exactamente para esto y produce visualizaciones interpretables. La validación contra eventos conocidos es un proxy de calidad del modelo: si el tópico de "deuda" no crece en 2001, algo anda mal.

## Experimento 3: Diferencias temáticas por tipo de sesión

**Pregunta:** ¿Existen diferencias temáticas entre sesiones ordinarias, especiales y extraordinarias?

### Qué se va a hacer

Comparar la distribución de tópicos entre los tres tipos principales de sesión (ordinarias ~340, especiales ~310, extraordinarias ~50).

### Cómo se va a hacer

- Se tomarán las distribuciones de tópicos (output del modelo elegido) y se agruparán por tipo de sesión.
- Para cada tipo, se calculará la distribución promedio de tópicos.
- **Test estadístico:** se aplicará un test de Kruskal-Wallis por tópico para determinar si la prevalencia de cada tópico difiere significativamente entre tipos de sesión ( $\alpha = 0.05$ ). Si el test es significativo, se aplicará Dunn's test como post-hoc para identificar qué pares difieren.
- **Visualización:** box plots o violin plots de la prevalencia de los tópicos más diferenciados por tipo de sesión.

## Por qué

Las sesiones extraordinarias son convocadas por el Poder Ejecutivo para temas específicos, por lo que deberían tener una distribución temática más concentrada que las ordinarias. Confirmar o refutar esto con datos aporta evidencia sobre la dinámica institucional. Además, si las "Expresiones en Minoría" (~200 sesiones) tienen perfil temático propio, eso revelaría qué temas la oposición elige llevar al recinto fuera del debate formal.

## Experimento 4: Diferencias temáticas por bloque político

**Pregunta:** ¿Se pueden identificar diferencias temáticas entre bloques o partidos políticos?

### Qué se va a hacer

Analizar la distribución de tópicos por familia política, aprovechando que el dataset ya está segmentado por intervención individual y que se cuenta con datos estructurados de pertenencia a bloque para cada diputado.

### Cómo se va a hacer

#### Eta­pa 1 — Vinculación intervenci­on-bloque:

- El dataset de intervenciones contiene el apellido del legislador y la fecha de la sesi­on. Se cruzar­á con el historial de diputados (`diputados_historial_limpio.csv`), que registra para cada legislador su bloque parlamentario con fechas de inicio y fin. El join se realizar­á por apellido + ventana temporal (la fecha de la sesi­on debe caer entre `bloque_inicio` y `bloque_fin`).
- Luego se mapear­á cada bloque a su familia pol­itica usando la tabla de correspondencia (`bloques_familia_politica.csv`), que agrupa los ~198 bloques en 10 familias: `peronismo_kirchnerismo`, `radicalismo`, `centro_derecha`, `centro_izquierda`, `derecha_liberal_libertaria`, `izquierda`, `peronismo_federal`, `provincial_federal`, `sin_bloque` y otros.
- Se filtrar­án las intervenciones del Presidente de la C­mara y del Secretario (son intervenciones procedimentales, no discursivas) y las intervenciones muy cortas (< 50 palabras), que suelen ser mociones de orden o aclaraciones sin contenido tem­atico.
- **Alcance temporal:** 2007-2026 (per­odo cubierto por los datos de bloques).
- Se reportar­á el coverage del matching: qu­e porcentaje de intervenciones se logr­ vincular con un bloque/familia pol­itica.

#### Eta­pa 2 — Topic Modelling a nivel intervenci­on:

- Se aplicar­á el modelo BERTopic ya entrenado en el Experimento 1 usando `.transform()` sobre las intervenciones individuales (inferencia, no reentrenamiento). Esto asigna a cada intervenci­on su t­opico dominante.

- Para las intervenciones largas (> 5.000 palabras), se segmentarán en chunks y se asignará el tópico modal del legislador en esa sesión.

**Etapas 3 — Análisis:**

- Se calculará la distribución de tópicos por familia política y se visualizará con heatmaps (familia × tópico, intensidad = proporción de intervenciones).
- **Test chi-cuadrado** sobre tabla de contingencia (familia\_politica × tópico dominante) para evaluar si la asociación familia-tópico es estadísticamente significativa ( $\alpha = 0.05$ ). Se reportará el V de Cramér como medida del tamaño del efecto.
- **TF-IDF por familia política:** como análisis complementario, se calculará TF-IDF tratando todo el texto de cada familia como un "documento" para identificar el vocabulario distintivo de cada sector. Esto permite ver diferencias léxicas más allá de los tópicos.
- **Análisis temporal cruzado:** para las familias políticas con suficiente masa de intervenciones (peronismo\_kirchnerismo, radicalismo, centro\_derecha, derecha\_liberal\_libertaria), se analizará cómo cambia su distribución de tópicos a lo largo de los períodos presidenciales (2007-2015 CFK, 2015-2019 Macri, 2019-2023 Fernández, 2023-2026 Milei).

**Por qué**

Esta es la pregunta que aporta más valor analítico y la que diferencia este trabajo de un análisis de tópicos estándar. La hipótesis es que cada familia política tiene "temas propios" que reflejan sus prioridades discursivas (e.g., seguridad y mercado para centro\_derecha/derecha\_liberal\_libertaria, derechos laborales y distribución para peronismo\_kirchnerismo, derechos civiles para centro\_izquierda). La disponibilidad de datos de bloques ya estructurados con fechas de pertenencia elimina la complejidad del parsing y permite un matching temporal preciso — un legislador que cambió de bloque (como se observa en el dataset) será asignado al bloque correcto según la fecha de cada intervención.

**Resumen del plan experimental**

| Experimento              | Input                    | Modelo                | Output                         | Métricas                                              |
|--------------------------|--------------------------|-----------------------|--------------------------------|-------------------------------------------------------|
| 1. Tópicos predominantes | Corpus completo (chunks) | LDA, NMF, BERTopic    | Lista de tópicos + top words   | Coherence (C_v), Diversity, evaluación cualitativa    |
| 2. Evolución temporal    | Exp 1 + timestamps       | Mejor modelo de Exp 1 | Prevalencia de tópicos × año   | Topics over Time, validación contra eventos conocidos |
| 3. Por tipo de sesión    | Exp 1 + tipo de sesión   | Mejor modelo de Exp 1 | Distribución de tópicos × tipo | Kruskal-Wallis, Dunn's test                           |

|                         |                                               |                      |                                            |                                               |
|-------------------------|-----------------------------------------------|----------------------|--------------------------------------------|-----------------------------------------------|
| 4. Por familia política | Intervenciones 2007-2026 + bloques + familias | BERTopic (transform) | Distribución de tópicos × familia política | Chi-cuadrado, V de Cramér, TF-IDF por familia |
|-------------------------|-----------------------------------------------|----------------------|--------------------------------------------|-----------------------------------------------|

## Herramientas y librerías

- **BERTopic** (v0.16+), **sentence-transformers**, **UMAP**, **HDBSCAN**
- **scikit-learn** (LDA, NMF, TF-IDF)
- **gensim** (coherence metrics)
- **spaCy** ([es\\_core\\_news\\_lg](#)) para NER y lematización
- **Plotly** para visualizaciones interactivas
- **scipy.stats** para tests estadísticos (Kruskal-Wallis, chi-cuadrado)